

Metody systemowe i decyzyjne


Zadanie regresji logistycznej

Szymon Zaręba

5 kwietnia 2017

Problem klasyfikacji

- **Zmienne wejściowe**, **atrybuty** (ang. *input variables, attributes*): $\mathbf{x} \in \mathcal{X}$
- **Zmienna wyjściowa**, **klasa**, **etykieta** (ang. *target variable, class label*):
 $y \in \{0, 1\}$ lub $y \in \{-1, 1\}$.
- **Problem:** dla $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ przewidzieć wartość klasy (etykiety) y dla nowego obiektu \mathbf{x} .
- Zgodnie z teorią decyzji wystarczy znać rozkład warunkowy $p(y|\mathbf{x})$, zatem chcemy go **modelować**.



Regresja logistyczna

- Model **regresji logistycznej** (ang. *logistic regression*):



$$p(y = 1|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^T \phi(\mathbf{x}))$$

- Funkcja sigmoidalna** (ang. *sigmoid function*):

$$\sigma(a) = \frac{1}{1 + \exp(-a)}$$

- Predykcja

$$y^* = \begin{cases} 1, & \text{jeśli } p(y = 1|\mathbf{x}, \mathbf{w}) \geq \theta, \\ 0, & \text{w przeciwnym przypadku.} \end{cases}$$



Funkcja wiarygodności

- Dane: $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, $\mathbf{y} = \{y_1, \dots, y_N\}$.
- **Warunkowa funkcja wiarygodności**
($\sigma_n \equiv \sigma(\mathbf{w}^T \phi(\mathbf{x}_n))$):

$$p(\mathbf{y}|\mathbf{X}, \mathbf{w}) = \prod_{n=1}^N \sigma_n^{y_n} (1 - \sigma_n)^{1-y_n}$$

- Logarytm funkcji wiarygodności z minusem:

$$-\ln p(\mathbf{y}|\mathbf{X}, \mathbf{w}) = -\sum_{n=1}^N \left(y_n \ln \sigma_n + (1 - y_n) \ln(1 - \sigma_n) \right)$$

- Postać σ_n zależnej od parametrów \mathbf{w} **nie pozwala** na analityczne rozwiązanie poprzez przyrównanie gradientu do zera.

Algorytm gradientu prostego

- Pseudokod:



Initialize \mathbf{w}

repeat

$$\mathbf{w} \leftarrow \mathbf{w} - \alpha \nabla_{\mathbf{w}} E(\mathbf{w})$$

until convergence

- Algorytm wrażliwy na dobór **parametru uczenia** α oraz **optima lokalne**.



Algorytm gradientu prostego

- Pseudokod:

Initialize \mathbf{w}

repeat

$\mathbf{w} \leftarrow \mathbf{w} - \alpha \nabla_{\mathbf{w}} E(\mathbf{w})$

until convergence

- Optymalizowana **funkcja celu** (podzielona przez N):

$$E(\mathbf{w}) = -\frac{1}{N} \sum_{n=1}^N (y_n \ln \sigma_n + (1 - y_n) \ln(1 - \sigma_n))$$

- **Gradient** funkcji celu względem parametrów:

$$\nabla_{\mathbf{w}} E(\mathbf{w}) = \dots$$

Stochastyczny algorytm gradientu prostego

- Pseudokod:

Initialize \mathbf{w}

repeat

for $n = 1$ to N **do**

$\mathbf{w} \leftarrow \mathbf{w} - \alpha \nabla_{\mathbf{w}} E_n(\mathbf{w})$

end for

until convergence

- **Przybliżenie** funkcji w n -tym kroku:

$$E_n(\mathbf{w}) = -y_n \ln \sigma_n - (1 - y_n) \ln(1 - \sigma_n)$$

- **Gradient** powyższej funkcji:

$$\nabla_{\mathbf{w}} E_n(\mathbf{w}) = \dots$$

Stochastyczny algorytm gradientu prostego

- SGD zbiega zazwyczaj **dużo szybciej** niż algorytm gradientu prostego.
- Często w pojedynczym kroku jest niestabilny i pojawiają się silne **drgania** (*ang. jitterings*).
- W celu redukcji tego efektu zamiast pojedynczej obserwacji, wykorzystuje się **małe paczki** danych (*ang. mini-batch*) o wielkości M .
- Wtedy dla pojedynczej paczki MB funkcja ma postać:

$$E_{MB}(\mathbf{w}) = -\frac{1}{M} \sum_{n \in MB} \left(y_n \ln \sigma_n + (1 - y_n) \ln(1 - \sigma_n) \right)$$

Regularyzacja

W rozważanym problemie wprowadzamy regularyzację ℓ_2 na parametry (oprócz wyrazu wolnego):

$$L_\lambda(\mathbf{w}) = L(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}_{-0}\|_2^2$$

gdzie $\mathbf{w}_{-0} = (w_1, \dots, w_{D-1})^T$ jest wektorem wag bez pierwszego parametru, tzw. wyrazu wolnego (ang. *bias*) w_0 , $\lambda > 0$ oznacza współczynnik regularyzacji.

Selekcja modelu

W rozważanym problemie mamy do czynienia z dwoma wielkościami, których nie wyuczamy w oparciu o dane:

- wartość progowa klasyfikacji θ
- wartość współczynnika regularyzacji λ

W celu oceny modelu w oparciu o wybrane wielkości obu parametrów, stosować będziemy miarę **F-measure**:

$$F(\mathcal{D}_{val}; \theta, \lambda, \mathbf{w}) = \frac{2TP}{2TP + FP + FN}$$